

WIKIPEDIA

Maschinelles Lernen

Maschinelles Lernen (ML) ist ein Oberbegriff für die „künstliche“ Generierung von Wissen aus Erfahrung: Ein künstliches System lernt aus Beispielen und kann diese nach Beendigung der Lernphase verallgemeinern. Dazu bauen Algorithmen beim maschinellen Lernen ein statistisches Modell auf, das auf Trainingsdaten beruht und welches gegen die Testdaten getestet wird. Das heißt, es werden nicht einfach die Beispiele auswendig gelernt (siehe Überanpassung), sondern Muster und Gesetzmäßigkeiten in den Lerndaten erkannt. So kann das System auch unbekannte Daten beurteilen (Lerntransfer) oder aber am Lernen unbekannter Daten scheitern (Überanpassung; englisch *overfitting*).^{[1][2]} Aus dem weiten Spektrum möglicher Anwendungen seien hier genannt: automatisierte Diagnoseverfahren, Erkennung von Kreditkartenbetrug, Aktienmarktanalysen, Klassifikation von Nukleotidsequenzen, Sprach- und Texterkennung sowie autonome Systeme.

Das Thema ist eng verwandt mit „Knowledge Discovery in Databases“ und „Data-Mining“, bei dem es jedoch vorwiegend um das Finden von *neuen* Mustern und Gesetzmäßigkeiten geht. Viele Algorithmen können für beide Zwecke verwendet werden. Methoden der „Knowledge Discovery in Databases“ können genutzt werden, um Lerndaten für „maschinelles Lernen“ zu produzieren oder vorzuverarbeiten. Im Gegenzug dazu finden Algorithmen aus dem maschinellen Lernen beim Data-Mining Anwendung. Zu unterscheiden ist der Begriff zudem von dem Begriff „Deep Learning“, welches nur eine mögliche Lernvariante mittels künstlicher neuronaler Netze darstellt.

Das Schließen von Daten auf (hypothetische) Modelle wird als Statistische Inferenz bezeichnet.

Inhaltsverzeichnis

Symbolische und nicht-symbolische Ansätze

Algorithmische Ansätze

- Überwachtes Lernen

- Unüberwachtes Lernen

- Bestärkendes Lernen

Automatisches Maschinelles Lernen

Siehe auch

- Literatur

- Weblinks

- Einzelnachweise

Symbolische und nicht-symbolische Ansätze

Beim maschinellen Lernen spielen Art und Mächtigkeit der Wissensrepräsentation eine wichtige Rolle. Man unterscheidet zwischen symbolischen Ansätzen, in denen das Wissen – sowohl die Beispiele als auch die induzierten Regeln – explizit repräsentiert ist, und nicht-symbolischen Ansätzen, wie neuronalen Netzen, denen zwar ein berechenbares Verhalten „antrainiert“ wird, die jedoch keinen Einblick in die erlernten Lösungswege erlauben; hier ist Wissen implizit repräsentiert.^[3]

Bei den symbolischen Ansätzen werden aussagenlogische und prädikatenlogische Systeme unterschieden. Vertreter der ersteren sind ID3 und sein Nachfolger C4.5. Letztere werden im Bereich der induktiven logischen Programmierung entwickelt.

Algorithmische Ansätze

Die praktische Umsetzung geschieht mittels Algorithmen. Verschiedene Algorithmen aus dem Bereich des maschinellen Lernens lassen sich grob in drei Gruppen einteilen:^[4] überwachtes Lernen (englisch *supervised learning*), unüberwachtes Lernen (englisch *unsupervised learning*) und bestärkendes Lernen (engl. *reinforcement learning*).

Überwachtes Lernen

→ *Hauptartikel: Überwachtes Lernen*

Der Algorithmus lernt eine Funktion aus gegebenen Paaren von Ein- und Ausgaben. Dabei stellt während des Lernens ein „Lehrer“ den korrekten Funktionswert zu einer Eingabe bereit. Ziel beim überwachten Lernen ist, dass dem Netz nach mehreren Rechengängen mit unterschiedlichen Ein- und Ausgaben die Fähigkeit antrainiert wird, Assoziationen herzustellen. Ein Teilgebiet des überwachten Lernens ist die automatische Klassifizierung. Ein Anwendungsbeispiel wäre die Handschrifterkennung.

Es lassen sich noch einige Unterkategorien für Überwachtes Lernen identifizieren, die in der Literatur häufiger erwähnt werden:

- Teilüberwachtes Lernen (englisch *semi-supervised learning*) Nur für einen Teil der Eingaben sind die dazugehörigen Ausgaben bekannt.^[5]
- Aktives Lernen (englisch *active learning*) Der Algorithmus hat die Möglichkeit, für einen Teil der Eingaben die korrekten Ausgaben zu erfragen. Dabei muss der Algorithmus die Fragen bestimmen, welche einen hohen Informationsgewinn versprechen, um die Anzahl der Fragen möglichst klein zu halten.^[6]
- Selbständiges Lernen (englisch *self-training*) Dieser Algorithmus kann in zwei wesentliche Komponenten eingeteilt werden. Die erste Algorithmuskomponente (Lehrer) leitet aus einem bestehenden gelabelten Datensatz weitere Datensätze mit Pseudolabeln her. Die zweite Algorithmuskomponente lernt nun aus dem erweiterten gelabelten Datensatz und wendet gefundene Muster für ihr eigenes Modell an.^[7]

Unüberwachtes Lernen

→ *Hauptartikel: Unüberwachtes Lernen*

Der Algorithmus erzeugt für eine gegebene Menge von Eingaben ein statistisches Modell, das die Eingaben beschreibt und erkannte Kategorien und Zusammenhänge enthält und somit Vorhersagen ermöglicht. Dabei gibt es Clustering-Verfahren, die die Daten in mehrere Kategorien einteilen, die sich durch charakteristische Muster voneinander unterscheiden. Das Netz erstellt somit selbständig Klassifikatoren, nach denen es die Eingabemuster einteilt. Ein wichtiger Algorithmus in diesem Zusammenhang ist der EM-Algorithmus, der iterativ die Parameter eines Modells so festlegt, dass es die gesehenen Daten optimal erklärt. Er legt dabei das Vorhandensein nicht beobachtbarer Kategorien zugrunde und schätzt abwechselnd die Zugehörigkeit der Daten zu einer der Kategorien und die Parameter, die die Kategorien ausmachen. Eine Anwendung des EM-Algorithmus findet sich beispielsweise in den Hidden Markov Models (HMMs). Andere Methoden des unüberwachten Lernens, z. B. Hauptkomponentenanalyse, verzichten auf die Kategorisierung. Sie zielen darauf ab, die beobachteten Daten in eine einfachere Repräsentation zu übersetzen, die sie trotz drastisch reduzierter Information möglichst genau wiedergibt.

Des Weiteren unterscheidet man zwischen Batch-Lernen, bei dem alle Eingabe/Ausgabe-Paare gleichzeitig vorhanden sind, und kontinuierlichem (sequentiellen) Lernen, bei dem sich die Struktur des Netzes zeitlich versetzt entwickelt.

Außerdem unterscheidet man zwischen Off-line-Lernen, bei dem alle Daten gespeichert sind und somit wiederholbar zugreifbar sind, und On-line-Lernen, bei dem die Daten nach einmaligem Ausführen und Anpassen der Gewichte verloren gehen. Batch Training ist immer off-line, On-line-Training ist immer inkrementell. Inkrementelles Lernen kann jedoch on-line oder off-line erfolgen.^[8]

Bestärkendes Lernen

→ *Hauptartikel: Bestärkendes Lernen*


Beim bestärkenden Lernen entwickeln Agenten selbständig eine Strategie, um erhaltene Belohnungen zu maximieren.^{[9][10]} Aufgrund seiner Allgemeingültigkeit wird dieses Gebiet auch in vielen anderen Disziplinen untersucht, z. B. in der Spieltheorie, der Kontrolltheorie, dem Operations Research, der Informationstheorie, der simulationsbasierten Optimierung, den Multiagentensystemen, der Schwarmintelligenz, der Statistik und den genetischen Algorithmen. Beim maschinellen Lernen wird die Umgebung normalerweise als Markov-Entscheidungsprozess (MDP) dargestellt. Viele Algorithmen des Verstärkungslernens verwenden Techniken der dynamischen Programmierung.^[11] Verstärkungslernalgorithmen setzen keine Kenntnis eines exakten mathematischen Modells des MDP voraus und werden eingesetzt, wenn exakte Modelle nicht durchführbar sind. Verstärkungslernalgorithmen werden in autonomen Fahrzeugen oder beim Lernen eines Spiels gegen einen menschlichen Gegner eingesetzt.

Automatisches Maschinelles Lernen

→ *Hauptartikel: Automatisiertes maschinelles Lernen*

Automatisches maschinelles Lernen automatisiert viele Schritte des maschinellen Lernens.

Siehe auch

 **Commons: Maschinelles Lernen** (https://commons.wikimedia.org/wiki/Categorie:Machine_learning?uselang=de) – Sammlung von Bildern, Videos und Audiodateien

- Föderales Lernen
- Empirische Risikominimierung

Literatur

- Andreas C. Müller, Sarah Guido: *Einführung in Machine Learning mit Python*. O'Reilly-Verlag, Heidelberg 2017, ISBN 978-3-96009-049-6.
- Christopher M. Bishop: *Pattern Recognition and Machine Learning*. Information Science and Statistics. Springer-Verlag, Berlin 2008, ISBN 978-0-387-31073-2.
- David J. C. MacKay: *Information Theory, Inference and Learning Algorithms*. Cambridge University Press, Cambridge 2003, ISBN 978-0-521-64298-9 (Online (<http://www.inference.phy.cam.ac.uk/mackay/itprnn/book.html>)).
- Trevor Hastie, Robert Tibshirani, Jerome Friedman: *The Elements of Statistical Learning*. Data Mining, Inference, and Prediction. 2. Auflage. Springer-Verlag, 2008, ISBN 978-0-387-84857-0 (stanford.edu (https://web.stanford.edu/~hastie/ElemStatLearn/printings/ESLII_print12.pdf) [PDF]).
- Thomas Mitchell: *Machine Learning*. Mcgraw-Hill, London 1997, ISBN 978-0-07-115467-3.
- D. Michie, D. J. Spiegelhalter: *Machine Learning, Neural and Statistical Classification*. In: *Ellis Horwood Series in Artificial Intelligence*. E. Horwood Verlag, New York 1994, ISBN 978-0-13-106360-0.
- Richard O. Duda, Peter E. Hart, David G. Stork: *Pattern Classification*. Wiley, New York 2001, ISBN 978-0-471-05669-0.
- David Barber: *Bayesian Reasoning and Machine Learning*. Cambridge University Press, Cambridge 2012, ISBN 978-0-521-51814-7.
- Arthur L. Samuel (1959): *Some studies in machine learning using the game of checkers*. IBM J Res Dev 3:210–229. doi:10.1147/rd.33.0210.
- Alexander L. Fradkov: *Early History of Machine Learning*. IFAC-PapersOnLine, Volume 53, Issue 2, 2020, Pages 1385-1390, doi:10.1016/j.ifacol.2020.12.1888.

Weblinks

- *Machine Learning Crash Course*. (<https://developers.google.com/machine-learning/crash-course/>) In: *developers.google.com*. Abgerufen am 6. November 2018 (englisch).
- Heinrich Vasce: *Machine Learning - Grundlagen*. (<https://www.computerwoche.de/a/machine-learning-darum-geht-s,3330413>) In: *Computerwoche*. 13. Juli 2017, abgerufen am 16. Januar 2019.
- golem.de, Miroslav Stimac: *So steigen Entwickler in Machine Learning ein* (<https://www.golem.de>)

m.de/news/programmiersprachen-pakete-ides-so-steigen-entwickler-in-machine-learning-ein-1811-137463.html), 12. November 2018

- [Introduction to Machine Learning \(http://robotics.stanford.edu/~nilsson/mlbook.html\)](http://robotics.stanford.edu/~nilsson/mlbook.html) (englisch)
- *Maschinen lernen – ohne Verstand ans Ziel*, Wissenschaftsfeature, Deutschlandfunk, 10. April 2016. Audio (http://ondemand-mp3.dradio.de/file/dradio/2016/04/10/dlf_20160410_1630_5dd0415d.mp3), Manuskript (http://www.deutschlandfunk.de/maschinelles-lernen-ohne-verstand-ans-ziel.740.de.html?dram:article_id=349980)

Einzelnachweise

1. Tobias Reitmaier: *Aktives Lernen für Klassifikationsprobleme unter der Nutzung von Strukturinformationen*. kassel university press, Kassel 2015, ISBN 978-3-86219-999-0, S. 1 (Google books (<https://books.google.de/books?id=6UioCgAAQBAJ&pg=PA1>)).
2. Lillian Pierson: *Data Science für Dummies*. 1. Auflage. Wiley-VCH Verlag, Weinheim 2016, ISBN 978-3-527-80675-1, S. 105 f. (Google books (<https://books.google.de/books?id=bqIIDAAQBAJ&pg=PT105>)).
3. Pat Langley: *The changing science of machine learning*. In: *Machine Learning*. Band 82, Nr. 3, 18. Februar 2011, S. 275–279, doi:10.1007/s10994-011-5242-y (<https://doi.org/10.1007/s10994-011-5242-y>).
4. <ftp://ftp.sas.com/pub/neural/FAQ.html#questions>
5. Ralf Mikut: *Data Mining in der Medizin und Medizintechnik*. KIT Scientific Publishing, 2008, ISBN 978-3-86644-253-5, S. 34 (Google books (https://books.google.de/books?id=s7KV_VPzzYC&pg=PA34)).
6. Paul Fischer: *Algorithmisches Lernen*. Springer-Verlag, 2013, ISBN 978-3-663-11956-2, S. 6–7 (Google books (<https://books.google.de/books?id=34HzBQAAQBAJ&pg=PA6>)).
7. *Self-training with Noisy Student improves ImageNet classification*. (<https://arxiv.org/abs/1911.04252v1>) In: *Arxiv*. Abgerufen am 20. Dezember 2019 (englisch).
8. ftp://ftp.sas.com/pub/neural/FAQ2.html#A_styles
9. Richard S. Sutton: *Reinforcement learning : an introduction*. Second edition Auflage. Cambridge, Massachusetts 2018, ISBN 978-0-262-03924-6.
10. *Machine Learning: Definition, Algorithmen, Methoden und Beispiele*. (<https://datasolut.com/was-ist-machine-learning/>) 11. August 2020, abgerufen am 31. Januar 2022.
11. Marco Wiering, Martijn van Otterlo: *Reinforcement learning : state-of-the-art*. Springer, Berlin 2012, ISBN 978-3-642-27645-3.

Abgerufen von „https://de.wikipedia.org/w/index.php?title=Maschinelles_Lernen&oldid=240080728“

Diese Seite wurde zuletzt am 11. Dezember 2023 um 08:30 Uhr bearbeitet.

Der Text ist unter der Lizenz „Creative-Commons Namensnennung – Weitergabe unter gleichen Bedingungen“ verfügbar; Informationen zu den Urhebern und zum Lizenzstatus eingebundener Mediendateien (etwa Bilder oder Videos) können im Regelfall durch Anklicken dieser abgerufen werden. Möglicherweise unterliegen die Inhalte jeweils zusätzlichen Bedingungen. Durch die Nutzung dieser Website erklären Sie sich mit den Nutzungsbedingungen und der Datenschutzrichtlinie einverstanden.
Wikipedia® ist eine eingetragene Marke der Wikimedia Foundation Inc.